

Detección de genotipos de porotos con técnicas de Aprendizaje Automático

Ciencia de Datos - 2025
Diego Jesús Scacchi



UNC

Universidad
Nacional
de Córdoba

FAMAF

Facultad de Matemática,
Astronomía, Física y
Computación

18/11/2025

Contenidos

- ➊ Introducción
- ➋ Dataset:Dry Beans
 - Genotipos
 - Diccionario de características
- ➌ Análisis Exploratorio de Datos
- ➍ Clasificadores
 - *Logistic Regression CV*
 - *Radial Basis Function SVM*
 - *Naïve Bayes*
 - *Random Forest*
 - *Gradient Boosting*
- ➎ Conclusiones

Motivación y origen del problema

- El poroto es una de las leguminosas más producidas y consumidas a nivel mundial. Existe gran diversidad genética.
- Clasificar semillas en términos generales permite adoptar técnicas de cultivo *sustentables*.
- Favorece significativamente a toda la cadena productiva.
- La selección manual implica procesos innecesariamente exhaustivos, especialmente a gran escala.

Multiclass classification of dry beans using computer vision and machine learning techniques



M. Koklu, İlker Ali Özkan • Published in *Computers and Electronics in...* 1 July 2020 • Agricultural and Food Sciences, Computer Science

243 Citations

Highly Influential Citations	25
Background Citations	51
Methods Citations	41
Results Citations	7

Variedades de porotos

- **Cali:** Color blanco. Semillas infladas y poseen forma de riñón.
- **Horoz:** Largas, cilíndricas, blancas y de tamaño mediano.
- **Dermason:** Semilla blanca más chata respecto al resto, con bordes redondos.
- **Seker:** Semillas grandes, blancas con forma redonda.
- **Bombay:** Es la especie más grande, de color blanco, y su morfología es ovalada y abultada.
- **Barbunya:** Es de color beige con rayas rojas. Su forma es ovalada casi redonda.
- **Sira:** Semillas pequeñas, de color blanco, con un extremo chato y otro redondo.



Características

Las características obtenidas fueron (todas expresadas en cantidad de píxeles):

1. **Area (A)**

Área del poroto (proyección 2D), i.e. cantidad de píxeles dentro de su borde.

$$A = \sum_{r, c \in R} 1$$

donde (r, c) representan una coordenada en la región R .

2. **Perimeter (P)**

Perímetro del poroto.

3. **Major Axis Length (L)**

Mayor distancia entre puntos del contorno del poroto.

4. **Minor Axis Length (l)**

Línea de mayor longitud que puede ser dibujada perpendicular al eje mayor.

5. **Aspect Ratio (K)**

Relación entre L y l

$$K = \frac{L}{l}$$

6. **Eccentricity (Ec)**

Excentricidad del elipse.

7. **Convex Area (C)**

Número de píxeles del polígono convexo más chico que logra cubrir el área del poroto.

Características

8. **Equivalent Diameter** (Ed)
Diámetro del círculo con área equivalente a la del poroto.

$$Ed = \sqrt{\frac{4A}{\pi}}$$

9. **Extent** (Ex)
Ratio entre el margen producido por la segmentación y el área del poroto.

$$Ex = \frac{A}{A_B}$$

donde A_B es el área de la caja rectangular.

10. **Solidity** (S)
También conocido como convexity.

$$S = \frac{A}{C}$$

11. **Roundness** (R)
Desviación respecto a un círculo.

12. **Compactness** (CO)
Mide cuán elongado es el poroto.

$$CO = \frac{Ed}{L}$$

13. **Shape Factor 1** (SF1)

$$SF1 = \frac{L}{A}$$

14. **Shape Factor 2** (SF2)

$$SF2 = \frac{l}{A}$$

15. **Shape Factor 3** (SF3)


$$SF3 = \frac{A}{\frac{L^2}{4}\pi}$$

16. **Shape Factor 4** (SF4)


$$SF4 = \frac{A}{\frac{L}{2}\frac{l}{2}\pi}$$

Desbalance de clases


Es claro que existe un desbalance entre las clases, particularmente **BOMBAY** siendo la que posee menos representación. La más frecuente es **DERMASON**.



Boxplots




Pairplot



Logistic Regression CV


Considerado como *baseline*, dado que alcanza una performance razonable con muy poco tiempo de cómputo, además de realizar fine-tuning sobre su hiperparámetro C.



- ♦ Mean Accuracy (cross-validation): 0.923677 ± 0.005986
- ♦ Accuracy en el set de test: 0.926184

SVM RBF


Aplicaremos *cross-validation* dos veces. Esto nos permitirá obtener un estimador insesgado sobre la capacidad de generalización del clasificador y a su vez hacer *fine-tuning* de sus hiperparámetros. La CV del modelo se hará con $K = 10$ folds y la de búsqueda de hiperparámetros con $K = 5$. Obtuvimos $C = 10$ y $\gamma = 0,1$.



- ♦ Mean Accuracy (cross-validation): 0.931759 ± 0.004670
- ♦ Accuracy en el set de test: 0.932795

Naïve Bayes


El tratamiento previo hecho con *PCA* preservó solo las características no correlacionadas, por lo tanto la hipótesis de independencia entre características no es tan lejana.



- ◆ Mean Accuracy (cross-validation): 0.888226 ± 0.006488
- ◆ Accuracy en el set de test: 0.896071


Random Forest

Basándonos en la implementación del árbol de decisión en el paper, optamos por un método de ensemble que logre contrarrestar las tendencias de sobreajuste, disminuyendo así la varianza del modelo.




- ◆ Mean Accuracy (cross-validation): 0.925698 ± 0.005599
- ◆ Accuracy en el set de test: 0.928755

Gradient Boosting



- ♦ Mean Accuracy (cross-validation): 0.925147 ± 0.004913
- ♦ Accuracy en el set de test: 0.925450

Accuracy por clase



Conclusiones

- Los resultados obtenidos muestran que el proceso de selección de porotos puede ser fácilmente automatizado, con un desempeño de por lo menos $\sim 90\%$.
- Puede haber problemas al momento de generalizar el clasificador a otras especies/leguminosas.
- Un abordaje no supervisado debería mostrar una formación natural de clusters que coincida con lo supervisado, obteniendo valores elevados de *Homogeneity*, *Completeness* y *V-Measure*.